

Relatório 6 - Vídeo: O Que É Ciência De Dados (I)

Gustavo Nunes da Silva


1. Introdução

O objetivo deste card foi entender na prática o que é ciência de dados a partir de dois vídeos com abordagens diferentes um mostrando mais a origem e o raciocínio por trás da área e o outro mostrando como é a profissão dentro de uma empresa.

2. Desenvolvimento

No primeiro vídeo que eu vi eles começam contando uma história da Segunda Guerra que resume bem a ideia. Os ingleses queriam blindar seus aviões de combate mas não dava pra blindar tudo senão o avião ficava pesado e não voava. Eles tinham que escolher onde colocar a blindagem olhando só para os aviões que voltavam da batalha. A ideia inicial era blindar onde tinha mais furo de bala mas um matemático chamado Abraham Wald percebeu que isso estava errado e foi isso que eu representei na Figura 1

Viés do sobrevivente



Fonte – Autoria própria (elaborado no Excalidraw).

Eu percebi que o problema ali era a amostra. Eles só olhavam quem voltava e quem voltava com furo na asa era porque tiro na asa não derrubava o avião. O motor e a cabine voltavam intactos porque quem levava tiro lá simplesmente explodia e não voltava para contar a história. Então a sacada foi blindar justamente onde não tinha furo. Esse é o tal do viés do sobrevivente e eu entendi que isso é o primeiro grande alerta da área porque o que falta nos dados afeta o resultado tanto quanto o que está lá e não tem cálculo que salve uma amostra ruim.

Depois disso o vídeo explica as coisas usando Kepler e Newton. Kepler olhou os dados e explicou o que acontecia dizendo que os planetas giram em elipses. Já o Newton foi além e descobriu o porquê com a gravitação e conseguiu prever coisas que nem existiam na época. Eu vi que a ciência de dados faz o mesmo caminho e o aprendizado de máquina é tipo o Newton porque prevê o futuro olhando os padrões nos dados.


Neste vídeo ele falou também que nada disso funciona se o dado for ruim. Achei muito legal o exemplo de que se você treina um sistema pra reconhecer moto só com foto de moto com gente em cima o sistema acha que a pessoa faz parte da moto e não reconhece uma moto parada sozinha. É o mesmo erro dos aviões só que em outra situação. Quando a base é boa acontece o contrário, e a modelagem consegue coisas impressionantes tipo o caso da loja Target que eu vi no vídeo. Eles descobriram que uma adolescente estava grávida pelo padrão de compras dela de hidratante e vitaminas e mandaram ofertas de bebê antes mesmo do pai dela saber.

Já no segundo vídeo o cara muda o foco e fala mais da profissão de verdade. Logo de cara ele quebra aquela ideia de que ciência de dados é só fazer modelo complexo ou código. Ele falou que o objetivo real é gerar impacto na empresa com análises e recomendações. Ele faz uma linha do tempo mostrando a mineração de dados em 1996 e depois em 2001 o William Cleveland juntando computação com estatística para criar a ciência de dados. Aí eu vi que entre 2003 e 2005 veio a web 2.0 com Facebook e YouTube gerando muito dado e em 2010 explodiu o Big Data que obrigou a galera a criar ferramentas pesadas como Hadoop e Spark. Percebi que a área surgiu porque sobrou dado e faltou ferramenta.

Ele também mostrou a pirâmide de necessidades da ciência de dados que eu coloquei na Figura 2.

Pirâmide atenção x retorno

a atenção vai pro topo e o retorno está no meio
pirâmide das necessidades da ciência de dados



cada camada só funciona se a de baixo estiver pronta

Fonte – Autoria própria (elaborado no Excalidraw)

A pirâmide ela vai da coleta na base até a inteligência artificial no topo. Cada camada depende da anterior então um modelo no topo apoiado numa base mal coletada produz um resultado ruim por mais sofisticado que seja. O vídeo mostra que a atenção de todo mundo fica no topo mas o dinheiro e o retorno de verdade estão no meio da pirâmide que é a parte de métricas e testes A/B. Ele explicou que as empresas grandes tem muito problema simples pra resolver e não precisam de IA complexa pra dar lucro.

O trabalho também muda pelo tamanho da empresa. Numa startup uma pessoa só faz tudo mas numa empresa grande eles dividem entre engenheiros analistas e pesquisadores. O legal é que os dois vídeos acabam se cruzando porque o Nerdologia fala muito do YouTube usando testes A/B pra prender o usuário e o outro vídeo mostra que essa é a parte mais importante da pirâmide de trabalho.

3. Conclusão

Concluindo eu achei que os dois vídeos se completam muito bem. O primeiro me explicou o raciocínio e o segundo me mostrou como o mercado funciona. Eu percebi que ciência de dados não é só fazer um modelo mas sim um caminho todo que vai desde pegar o dado até tomar a decisão. O caso do avião na guerra e a base da pirâmide mostram que o trabalho que menos aparece que é limpar e organizar os dados é o que realmente sustenta tudo e dá resultado no final das contas.

4. Referências

NERDOLOGIA TECH. O que é ciência de dados. YouTube, 26 jul. 2018. Disponível em: <https://www.youtube.com/watch?v=ykSILAQQu6o>.

JOMA TECH. What REALLY is Data Science? Told by a Data Scientist. YouTube, [s.d.]. Disponível em: <https://www.youtube.com/watch?v=xC-c7E5PK0Y>.

ROGATI, Monica. The AI Hierarchy of Needs. Hackernoon, 2017. Disponível em: <https://hackernoon.com/the-ai-hierarchy-of-needs-18f111fcc007>.