

Relatório 5 - Prática: Estatística p/ Aprendizado de Máquina (I)

Gustavo Nunes da Silva


1. Introdução

O objetivo deste card foi entender melhor na prática a parte de estatística que aparece no aprendizado de máquina passando pelos tipos de dados e pelas medidas como média, mediana e moda até chegar nas distribuições, correlação e probabilidade condicional. Eu acompanhei as aulas do curso e fui reproduzindo os exemplos em Python usando NumPy, SciPy, Matplotlib e Seaborn para fazer os cálculos e também visualizar o que estava acontecendo.

2. Desenvolvimento

O primeiro passo foi entender a diferença entre dados numéricos, categóricos e ordinais. No começo eu achei que isso seria mais uma questão de nomes, mas durante os exercícios ficou claro pra mim que essa classificação muda o tipo de cálculo que pode ser feito. Nos dados numéricos faz sentido calcular a média, por exemplo, nos categóricos não existe uma ordem e o mais indicado é trabalhar com frequência, e nos ordinais existe uma ordem, mas a diferença entre as categorias não é necessariamente igual, então a mediana acaba fazendo mais sentido que a média. Percebi que classificar errado pode fazer eu chegar em um número que parece certo, mas que na prática não representa o dado.

Depois passei para média, mediana e moda. A média é bem simples de calcular, mas o exercício mostrou bem o problema dela quando aparecem valores muito fora do normal. Em um conjunto com dez mil rendas, perto de vinte e sete mil, eu coloquei um valor de um bilhão e a média foi para perto de cento e vinte e sete mil, enquanto a mediana mudou só dois reais. Pra mim, esse foi um dos exemplos mais fáceis de entender porque ficou claro como um único valor pode distorcer a média. Isso também fez ligação com o tratamento de dados ausentes que eu tinha visto no card anterior e daí vieram os momentos da distribuição que ajudam a medir esse tipo de comportamento e que eu mostrei na imagem.




Fonte – Autoria própria (elaborado no Excalidraw).

A variância mede o quanto os valores se afastam da média usando os quadrados desses desvios e o desvio padrão é a raiz da variância o que faz ele voltar para a mesma unidade dos dados e por isso fica mais fácil de interpretar. Depois vieram o terceiro e o quarto momentos. A assimetria que o skew mostra indica para qual lado a cauda da distribuição está maior e foi isso que ajudou a entender a imagem porque numa distribuição simétrica média mediana e moda ficam no mesmo lugar e quando a cauda aumenta a média é puxada para esse lado enquanto a moda continua mais perto do pico e a mediana fica no meio. A curtose medida pelo kurtosis mostra o peso dessas caudas e a presença de valores extremos. Quando reproduzi isso em uma amostra normal gerada no NumPy os valores ficaram perto de zero como era esperado.

Depois trabalhei com as funções de probabilidade e a diferença que mais me confundiu foi entre PDF e PMF. A PDF é usada para variáveis contínuas e o valor mostrado no gráfico representa uma densidade e não uma probabilidade direta então a probabilidade é obtida pela área em um intervalo. Já na PMF cada valor possível de uma variável discreta tem sua própria probabilidade. A partir disso ficou mais fácil entender as distribuições da aula a normal a uniforme e a exponencial foram tratadas como contínuas usando a PDF enquanto a binomial e a de Poisson foram usadas como discretas com a PMF. Também achei interessante a diferença entre exponencial e Poisson porque uma mostra o tempo até um evento enquanto a outra conta quantos eventos acontecem dentro de um intervalo.

Os percentis dividem os dados ordenados em cem partes então o percentil 50 acaba sendo a própria mediana. O que mais me chamou atenção foi usar eles para observar valores extremos sem depender tanto da média porque comparar por exemplo o percentil 90 com o 20 mostra a diferença dos dados sem deixar um valor absurdo dominar tudo. Depois veio a covariância que mostra se duas variáveis variam juntas mas o valor dela depende da escala usada por cada uma então sozinho ele não diz muito sobre a força da relação. A correlação resolve isso normalizando a covariância entre menos um e um. Entendi isso como uma forma mais fácil de interpretar o mesmo tipo de relação. Durante o exercício eu também encontrei um erro na fórmula feita manualmente porque o cálculo estava dividindo duas vezes pelo desvio padrão da mesma variável em vez de usar o desvio de cada uma e por isso apareceu um valor perto de menos sete. Como correlação não pode sair dessa faixa eu já percebi que tinha alguma coisa errada e conferindo com a função do NumPy apareceu menos zero vírgula cinco.

Na parte final eu trabalhei com probabilidade condicional. O exercício simulou cem mil pessoas separadas por idade e a chance de compra aumentava conforme a idade. Quando calculei a chance de uma pessoa comprar sabendo que ela tinha trinta anos o resultado foi diferente da chance geral de compra e isso mostrou que as duas variáveis não eram independentes. A imagem ajuda a mostrar essa relação e leva até o teorema de Bayes.



Fonte – Autoria própria (elaborado no Excalidraw).

O teorema de Bayes permite fazer o caminho contrário e descobrir a probabilidade de uma hipótese usando uma evidência. Isso aparece bastante em aprendizado de máquina porque normalmente eu tenho dados anteriores e quero estimar a chance de uma determinada classe para uma observação nova. Um detalhe que quase passou despercebido foi deixar a semente fixa antes da simulação porque sem isso cada vez que eu executasse o código os números mudariam e eu não conseguiria comparar direito com o resultado da aula.

Depois usei a visualização para conferir os resultados. No Matplotlib eu fiz histogramas e curvas ajustando eixos limites e marcações e percebi que o gráfico ajuda a enxergar coisas que o número sozinho não mostra como a assimetria e o peso das caudas. Também fiz um boxplot com valores muito acima e abaixo do restante e ficou bem visível os pontos extremos fora da caixa que é praticamente a mesma situação do valor de um bilhão que puxou a média. No Seaborn achei o pairplot o mais interessante porque ele coloca todas as variáveis numéricas para comparar duas a duas e já deixa algumas relações visíveis antes mesmo de calcular a correlação. O heatmap também ajudou porque mostra por cores como uma medida muda no cruzamento de duas dimensões.

3. Conclusão

A prática deixou mais claro pra mim que estatística não é uma parte separada do aprendizado de máquina porque antes de pensar no modelo eu preciso entender os dados e saber o que os números estão mostrando. O que mais ficou importante pra mim foi perceber como os assuntos se ligam a variância leva ao desvio padrão a covariância pode virar correlação a assimetria ajuda a explicar a diferença entre média e mediana e o tipo de variável define como a distribuição vai ser trabalhada. No fim também entendi que o problema muitas vezes não aparece como erro no código e sim como um número que parece normal mas está descrevendo outra coisa e os gráficos ajudam bastante a perceber isso.

4. Referências

TADEWALD, Rodrigo Soares; PIERIAN DATA INTERNATIONAL. Python para Data Science e Machine Learning – COMPLETO. Udemy, 2019.